

Taller: Estadística Descriptiva

Estadística Fundamental para Ciencias de la Salud

Giovany Babativa-Márquez, PhD

NOTA: Los ejercicios están agrupados por tema y cubren conceptos básicos, medidas de tendencia central, dispersión, posición, datos atípicos, tablas de contingencia y visualización. Se incluyen las soluciones y el código R. Si tiene comentarios, escriba a jgbabativam@unal.edu.co. Cualquier copia o adaptación debe citar al autor.

1 Conceptos Básicos: Población, Muestra y Escalas de Medición

1.1 Ejercicio 1

En un estudio sobre el control de la hipertensión arterial (HTA) en adultos mayores atendidos en un hospital universitario de Bogotá, se seleccionaron 150 pacientes de los 1,200 que asisten al programa de crónicos.

- Defina la **población** y la **muestra** en este estudio.
- Para cada variable registrada, identifique si es un **parámetro** o un **estadístico**: (i) media de presión arterial sistólica (PAS) de los 1,200 pacientes; (ii) proporción de pacientes con PAS controlada en los 150 seleccionados; (iii) desviación estándar de la PAS en los 150 pacientes.
- ¿Por qué es importante distinguir entre parámetro y estadístico en la práctica clínica?

Solución:

- Población:** todos los pacientes adultos mayores con HTA inscritos en el programa de crónicos del hospital ($N = 1,200$ pacientes).
 - Muestra:** los 150 pacientes seleccionados para el estudio ($n = 150$).
- Clasificación:

Medida	Tipo	Justificación
(i) Media PAS de los 1,200	Parámetro (μ)	Se calcula sobre toda la población
(ii) Proporción en los 150	Estadístico ($\hat{p}$)	Se calcula sobre la muestra
(iii) DE de los 150	Estadístico (s)	Se calcula sobre la muestra

- En la práctica clínica, los parámetros son los valores “verdaderos” de la población (generalmente desconocidos), mientras que los estadísticos son estimaciones calculadas a partir de muestras. Una decisión clínica basada en estadísticos siempre lleva incertidumbre, lo que justifica el uso de intervalos de confianza y pruebas de hipótesis.

1.2 Ejercicio 2

Un equipo de fisioterapia registra las siguientes variables en 80 pacientes con lesión musculoesquelética. Clasifique cada variable según su **escala de medición** (nominal, ordinal, de intervalo o de razón) y justifique:

- Tipo de lesión: desgarro, esguince, fractura, tendinitis
- Intensidad del dolor según escala EVA (0–10)
- Temperatura corporal en grados Celsius
- Rango de movimiento (ROM) articular en grados
- Número de sesiones de fisioterapia completadas
- Sexo del paciente (masculino/femenino)
- Nivel de funcionalidad según escala de Barthel (0–100 puntos)
- Tiempo de evolución de la lesión en semanas

Solución:

Variable	Escala	Justificación
a) Tipo de lesión	Nominal	Categorías sin orden natural
b) EVA (0–10)	Ordinal	Hay orden, pero las diferencias entre valores no son equiparables
c) Temperatura (°C)	Intervalo	Diferencias equiparables, pero el cero es arbitrario (0°C no es ausencia de temperatura)
d) ROM en grados	Razón	Cero absoluto (0° = sin movimiento), razones tienen sentido
e) Número de sesiones	Razón	Cero absoluto, es un conteo
f) Sexo	Nominal	Categorías sin orden
g) Escala Barthel	Ordinal	Hay orden, pero los intervalos no son necesariamente iguales
h) Tiempo en semanas	Razón	Cero absoluto, diferencias y razones tienen sentido

1.3 Ejercicio 3

En un estudio multicéntrico sobre EPOC (Enfermedad Pulmonar Obstructiva Crónica) participaron cuatro hospitales de Colombia. Se desea conocer el nivel promedio de saturación de oxígeno (SpO₂) en la población con EPOC moderado-severo.

- Identifique la unidad estadística, la variable de estudio y su escala.
- ¿Cuál sería la diferencia entre hacer un **censo** y una **muestra** en este contexto?
- Si la SpO₂ media de la muestra de 200 pacientes es $\bar{x} = 89.3\%$ y la media real de todos los pacientes con EPOC moderado-severo de los cuatro hospitales es $\mu = 88.7\%$, ¿cuánto es el **error de estimación** $|\bar{x} - \mu|$?
- Calcule el error de estimación en R.

Solución:

- Unidad estadística:** cada paciente con diagnóstico de EPOC moderado-severo en los cuatro hospitales.
 - Variable de estudio:** saturación de oxígeno (SpO₂).
 - Escala:** de razón (tiene cero absoluto y las proporciones son interpretables).
- Un **censo** mediría la SpO₂ de todos los pacientes con EPOC en los cuatro hospitales (da el parámetro exacto, pero es costoso y puede no ser factible). Una **muestra** selecciona un subconjunto representativo, permite estimaciones estadísticas con menor costo y tiempo, pero introduce incertidumbre.
- Error de estimación: $|\bar{x} - \mu| = |89.3 - 88.7| = 0.6\%$

```
# Cálculo del error de estimación
x_barra <- 89.3 # media muestral de SpO2
mu      <- 88.7 # parámetro poblacional
```

```

error    <- abs(x_barra - mu)
cat("Error de estimación:", error, "%\n")

## Error de estimación: 0.6 %

cat("Interpretación: La media muestral sobreestima el parámetro en", error, "puntos porcentuales\n")

## Interpretación: La media muestral sobreestima el parámetro en 0.6 puntos porcentuales

```

2 Medidas de Tendencia Central

2.1 Ejercicio 4

Los siguientes datos corresponden a los **días de hospitalización** de 8 pacientes con neumonía adquirida en la comunidad en una sala de medicina interna:

3, 5, 4, 7, 8, 5, 6, 9

- Calcule manualmente la **media aritmética**, la **mediana** y la **moda**.
- ¿Cuál medida de tendencia central describe mejor este conjunto de datos? Justifique.
- Verifique los resultados con R.

Solución:

- Datos ordenados: 3, 4, 5, 5, 6, 7, 8, 9 ($n = 8$)

Media:

$$\bar{x} = \frac{3 + 5 + 4 + 7 + 8 + 5 + 6 + 9}{8} = \frac{47}{8} = \mathbf{5.875} \text{ días}$$

Mediana: Con $n = 8$ pares, la mediana es el promedio de los valores en las posiciones 4 y 5:

$$\text{Mediana} = \frac{x_{(4)} + x_{(5)}}{2} = \frac{5 + 6}{2} = \mathbf{5.5} \text{ días}$$

Moda: El valor 5 aparece dos veces. Moda = **5** días.

- La **media** es la medida más adecuada aquí, ya que todos los datos son numéricos, la distribución es relativamente simétrica y no hay valores extremos que la distorsionen significativamente. Si hubiera un valor atípico (ej. 30 días), sería preferible la mediana.

```

# Días de hospitalización
dias <- c(3, 5, 4, 7, 8, 5, 6, 9)
dias_ord <- sort(dias)
cat("Datos ordenados:", dias_ord, "\n")

```

```
## Datos ordenados: 3 4 5 5 6 7 8 9
```

```
cat("Media:", mean(dias), "\n")
```

```
## Media: 5.875
```

```
cat("Mediana:", median(dias), "\n")
```

```
## Mediana: 5.5
```

```
# Moda (toca manual, R no tiene función moda)
tabla_freq <- table(dias)
moda <- as.numeric(names(tabla_freq[tabla_freq == max(tabla_freq)]))
cat("Moda:", moda, "\n")
```

```
## Moda: 5
```

2.2 Ejercicio 5

Se registraron los tiempos de espera (en minutos) de **7 pacientes** en urgencias: 8, 12, 15, 18, 20, 22, 28.

- Calcule la media y mediana.
- Ahora se incorpora un octavo paciente con tiempo de espera de **95 minutos** (valor atípico). Calcule nuevamente la media y la mediana.
- Compare los resultados y explique el efecto del valor atípico sobre cada medida.

Solución:

- Con 7 datos: 8, 12, 15, 18, 20, 22, 28

$$\bar{x}_7 = \frac{8 + 12 + 15 + 18 + 20 + 22 + 28}{7} = \frac{123}{7} \approx \mathbf{17.57 \text{ min}}$$

Posición de la mediana: $\frac{7+1}{2} = 4$, entonces Mediana = $x_{(4)} = \mathbf{18 \text{ min}}$.

- Con 8 datos incluyendo el 95: ordenados: 8, 12, 15, 18, 20, 22, 28, 95

$$\bar{x}_8 = \frac{123 + 95}{8} = \frac{218}{8} = \mathbf{27.25 \text{ min}}$$

Mediana (promedio de posiciones 4 y 5): $\frac{18+20}{2} = \mathbf{19 \text{ min}}$.

- El valor atípico de 95 min aumentó la **media** en $27.25 - 17.57 = 9.68$ minutos (+55%), mientras que la mediana solo aumentó de 18 a 19 min (+5.6%). Esto ilustra que la **media es sensible a valores extremos** mientras que la **mediana es robusta**.

```
# Sin valor atípico
t7 <- c(8, 12, 15, 18, 20, 22, 28)
cat("Sin atípico:\n")
```

```
## Sin atípico:
```

```
cat(" Media:", round(mean(t7), 2), "min\n")
```

```
## Media: 17.57 min
```

```
cat(" Mediana:", median(t7), "min\n\n")
```

```
## Mediana: 18 min
```

```
# Con valor atípico
t8 <- c(t7, 95)
cat("Con valor atípico (95 min):\n")
```

```
## Con valor atípico (95 min):
```

```
cat(" Media:", round(mean(t8), 2), "min\n")
```

```
## Media: 27.25 min
```

```
cat("  Mediana:", median(t8), "min\n")

##  Mediana: 19 min

cat("\nCambio en media:", round(mean(t8) - mean(t7), 2), "min\n")

##
## Cambio en media: 9.68 min

cat("Cambio en mediana:", median(t8) - median(t7), "min\n")

## Cambio en mediana: 1 min
```

2.3 Ejercicio 6

Un estudio de manejo del dolor posquirúrgico registró la **puntuación EVA** (Escala Visual Análoga, 0–10) de 10 pacientes a las 24 horas post-cirugía ortopédica:

2, 4, 3, 5, 3, 7, 3, 6, 4, 5

- Calcule la media, mediana y moda.
- ¿La distribución es simétrica, sesgada a la derecha o sesgada a la izquierda? Use la relación entre media y mediana para responder.
- Interprete clínicamente la medida de tendencia central más apropiada.

Solución:

- Datos ordenados: 2, 3, 3, 3, 4, 4, 5, 5, 6, 7 ($n = 10$)

$$\bar{x} = \frac{2 + 4 + 3 + 5 + 3 + 7 + 3 + 6 + 4 + 5}{10} = \frac{42}{10} = 4.2$$

Mediana (promedio de posiciones 5 y 6): $\frac{4+4}{2} = 4.0$

Moda: el valor 3 aparece 3 veces. Moda = 3

- Como $\bar{x} = 4.2 > \text{Mediana} = 4.0 > \text{Moda} = 3$, la distribución presenta un leve **sesgo a la derecha** (asimetría positiva), indicado por los valores más altos de EVA jalando la media hacia arriba.
- La **mediana** de 4 puntos sería la medida más adecuada para reportar la tendencia central, ya que la distribución es ligeramente asimétrica. Clínicamente indica que el 50% de los pacientes presenta un dolor moderado (EVA = 4) y el otro 50% dolor leve-moderado (EVA = 4) a las 24 horas postcirugía, sugiriendo la necesidad de reforzar la analgesia posoperatoria.

```
# Puntuaciones EVA
eva <- c(2, 4, 3, 5, 3, 7, 3, 6, 4, 5)
eva_ord <- sort(eva)
cat("Datos ordenados:", eva_ord, "\n")

## Datos ordenados: 2 3 3 3 4 4 5 5 6 7

cat("Media:", mean(eva), "\n")

## Media: 4.2

cat("Mediana:", median(eva), "\n")

## Mediana: 4
```

```
tabla_eva <- table(eva)
moda_eva <- as.numeric(names(tabla_eva[tabla_eva == max(tabla_eva)]))
cat("Moda:", moda_eva, "\n")
```

```
## Moda: 3
```

```
cat("Relación: Media > Mediana > Moda -> sesgo a la derecha\n")
```

```
## Relación: Media > Mediana > Moda -> sesgo a la derecha
```

2.4 Ejercicio 7

En un programa de rehabilitación pulmonar, tres grupos de pacientes con EPOC realizaron pruebas de capacidad funcional. Se registró el **ROM (rango de movimiento) de hombro** en grados antes de iniciar el programa:

Grupo	n (pacientes)	ROM medio (°)
Leve	25	95
Moderado	30	102
Severo	20	88

Calcule la **media ponderada** del ROM para los 75 pacientes en total.

Solución:

$$\bar{x}_p = \frac{\sum n_i \cdot \bar{x}_i}{\sum n_i} = \frac{25(95) + 30(102) + 20(88)}{25 + 30 + 20}$$

$$\bar{x}_p = \frac{2375 + 3060 + 1760}{75} = \frac{7195}{75} = \mathbf{95.93^\circ}$$

```
# Media ponderada
```

```
n_grupos <- c(25, 30, 20)
```

```
rom_medios <- c(95, 102, 88)
```

```
media_pond <- sum(n_grupos * rom_medios) / sum(n_grupos)
```

```
cat("Media ponderada del ROM:", round(media_pond, 2), "grados\n")
```

```
## Media ponderada del ROM: 95.93 grados
```

```
cat("n total:", sum(n_grupos), "pacientes\n")
```

```
## n total: 75 pacientes
```

```
# Verificación paso a paso
```

```
cat("\nProductos n_i * x_i:\n")
```

```
##
```

```
## Productos n_i * x_i:
```

```
for(i in 1:3) {
```

```
  cat(" Grupo", i, ":", n_grupos[i], "x", rom_medios[i], "=", n_grupos[i]*rom_medios[i], "\n")
}
```

```
## Grupo 1 : 25 x 95 = 2375
## Grupo 2 : 30 x 102 = 3060
## Grupo 3 : 20 x 88 = 1760

cat("Suma productos:", sum(n_grupos * rom_medios), "\n")

## Suma productos: 7195
```

2.5 Ejercicio 8

Se midió la **frecuencia cardíaca en reposo** (lpm) de 20 pacientes con insuficiencia cardíaca antes de iniciar rehabilitación cardíaca. Los datos agrupados son:

Intervalo (lpm)	Frecuencia
[60, 70)	4
[70, 80)	8
[80, 90)	5
[90, 100)	3

- Calcule la media aritmética a partir de datos agrupados.
- Interprete el resultado clínicamente.

Solución:

Para datos agrupados, se usa el punto medio de cada intervalo (m_i):

Intervalo	m_i	f_i	$m_i \cdot f_i$
[60, 70)	65	4	260
[70, 80)	75	8	600
[80, 90)	85	5	425
[90, 100)	95	3	285
Total		20	1570

$$\bar{x} = \frac{\sum m_i f_i}{n} = \frac{1570}{20} = \mathbf{78.5 \text{ lpm}}$$

- La frecuencia cardíaca media de los pacientes antes de la rehabilitación es **78.5 lpm**. Esto está dentro del rango normal (60–100 lpm), aunque es esperablemente más elevada que la de adultos sanos, reflejando la respuesta compensadora del corazón insuficiente.

```
# Media con datos agrupados
puntos_medios <- c(65, 75, 85, 95)
frecuencias   <- c(4, 8, 5, 3)

n_total <- sum(frecuencias)
media_agrup <- sum(puntos_medios * frecuencias) / n_total

cat("Media (datos agrupados):", media_agrup, "lpm\n")

## Media (datos agrupados): 78.5 lpm

cat("n total:", n_total, "pacientes\n")

## n total: 20 pacientes
```

```
# Tabla resumen
df_agrup <- data.frame(
  Intervalo = c("[60,70)", "[70,80)", "[80,90)", "[90,100)"),
  m_i = puntos_medios,
  f_i = frecuencias,
  m_i_fi = puntos_medios * frecuencias
)
knitr::kable(df_agrup, col.names = c("Intervalo", "Punto medio (m_i)", "Frec. (f_i)", "m_i × f_i"),
  caption = "Media con datos agrupados: FC en rehabilitación cardíaca")
```

Table 6: Media con datos agrupados: FC en rehabilitación cardíaca

Intervalo	Punto medio (m_i)	Frec. (f_i)	m_i × f_i
[60,70)	65	4	260
[70,80)	75	8	600
[80,90)	85	5	425
[90,100)	95	3	285

2.6 Ejercicio 9

En una clínica de rehabilitación musculoesquelética se midió la distancia recorrida en la **prueba de 6 minutos marcha (6MWT)** de 15 pacientes con EPOC. Los datos en metros son:

280, 310, 295, 320, 265, 330, 305, 340, 290, 315, 275, 345, 300, 285, 310

- Use R para calcular media, mediana y moda.
- Construya un histograma y un diagrama de cajas.
- Describa la distribución y su relevancia clínica.

Solución:

```
# Distancia en prueba 6MWT
seis_mwt <- c(280, 310, 295, 320, 265, 330, 305, 340, 290, 315, 275, 345, 300, 285, 310)

cat("n =", length(seis_mwt), "pacientes\n")

## n = 15 pacientes
cat("Media:", round(mean(seis_mwt), 2), "m\n")

## Media: 304.33 m
cat("Mediana:", median(seis_mwt), "m\n")

## Mediana: 305 m

# Moda
tabla_mwt <- table(seis_mwt)
moda_mwt <- as.numeric(names(tabla_mwt[tabla_mwt == max(tabla_mwt)]))
cat("Moda:", moda_mwt, "m\n")


## Moda: 310 m
df_mwt <- data.frame(distancia = seis_mwt)
```



```
p1 <- ggplot(df_mwt, aes(x = distancia)) +
  geom_histogram(bins = 6, fill = "#1565C0", color = "white", alpha = 0.8) +
  geom_vline(xintercept = mean(seis_mwt), color = "#C62828", linetype = "dashed", linewidth = 1) +
  geom_vline(xintercept = median(seis_mwt), color = "#2E7D32", linetype = "dotted", linewidth = 1) +
  labs(x = "Distancia (m)", y = "Frecuencia",
       title = "Prueba 6MWT - Pacientes con EPOC",
       caption = "Rojo discontinuo = media | Verde punteado = mediana") +
  theme_minimal()

p2 <- ggplot(df_mwt, aes(y = distancia)) +
  geom_boxplot(fill = "#42A5F5", color = "#1565C0", alpha = 0.8, width = 0.4) +
  labs(y = "Distancia (m)", title = "Diagrama de cajas") +
  theme_minimal()

# Mostrar ambos gráficos
gridExtra::grid.arrange(p1, p2, ncol = 2)
```



- c) La distribución de la 6MWT muestra una media de ~305 m y mediana similar, indicando **distribución aproximadamente simétrica**. La distancia media está por debajo del umbral de 350 m frecuentemente citado como límite funcional en EPOC, confirmando la capacidad funcional reducida de estos pacientes. Los valores de 265–345 m son consistentes con EPOC moderado-severo.

2.7 Ejercicio 10

Compare la **media** y la **mediana** como medidas de tendencia central para las siguientes variables clínicas. Indique cuál es más apropiada en cada caso y justifique:

- Días de estancia hospitalaria en UCI (distribución con cola derecha larga)
- Temperatura corporal de pacientes febriles (distribución aproximadamente simétrica)
- Escala de Barthel (funcionalidad: 0–100) en pacientes con ACV agudo
- Número de medicamentos por paciente en una sala de polifarmacia

Solución:

Variable	Medida preferida	Justificación
a) Días en UCI	Mediana	La distribución asimétrica (cola derecha) hace que la media sea inflada por estancias muy prolongadas
b) Temperatura corporal	Media	Distribución simétrica, sin valores extremos; la media es el estimador óptimo
c) Escala Barthel post-ACV	Mediana	Datos ordinales, distribución asimétrica esperada (muchos pacientes con puntaje muy bajo)
d) N° de medicamentos	Mediana	Posible distribución asimétrica; algunos pacientes con polifarmacia extrema sesgan la media

2.8 Ejercicio 11

Un artículo científico reporta que la **estancia media** en UCI de pacientes con sepsis severa fue de $\bar{x} = 14.3$ días (DE = 8.7) con una mediana de **7.2 días**.

- ¿Qué indica la gran diferencia entre media y mediana?
- ¿En qué dirección está sesgada la distribución?
- Si se publicara solo la media, ¿podría generar una interpretación incorrecta? Explique con un ejemplo clínico.

Solución:

- La gran diferencia entre $\bar{x} = 14.3$ y mediana = 7.2 días indica que hay **valores atípicos muy elevados** (estancias muy prolongadas) que elevan artificialmente la media. La mayoría de los pacientes tienen estancias más cortas (ceranas a la mediana de 7.2 días).
- La distribución está **sesgada a la derecha (asimetría positiva)**. La media > mediana, típico de distribuciones con cola larga hacia valores altos.
- Sí. Si un hospital reporta solo $\bar{x} = 14.3$ días para planificar recursos, sobreestimaría el tiempo de cama típico. En la práctica, la mayoría de los pacientes (representados por la mediana) salen en ~7 días. Solo unos pocos casos complicados alargan su estancia; reportar solo la media podría llevar a subdimensionar la capacidad para casos moderados o a sobreasignar recursos para casos típicos.

3 Medidas de Dispersión

3.1 Ejercicio 12

Se registró la **frecuencia cardíaca** (lpm) de 6 pacientes al inicio de una sesión de rehabilitación cardíaca: 68, 72, 75, 80, 72, 65.

- Calcule manualmente: rango, varianza muestral (s^2) y desviación estándar (s).
- Interprete la desviación estándar en el contexto clínico.
- Verifique con R.

Solución:

- a) Datos: 65, 68, 72, 72, 75, 80 (ordenados), $n = 6$

Rango: $R = 80 - 65 = 15$ lpm

Media: $\bar{x} = \frac{65+68+72+72+75+80}{6} = \frac{432}{6} = 72$ lpm

Varianza muestral:

$$s^2 = \frac{\sum_{i=1}^n (x_i - \bar{x})^2}{n - 1}$$

x_i	$x_i - \bar{x}$	$(x_i - \bar{x})^2$
65	-7	49
68	-4	16
72	0	0
72	0	0
75	3	9
80	8	64
Suma		138

$$s^2 = \frac{138}{6 - 1} = \frac{138}{5} = 27.6 \text{ lpm}^2$$

$$s = \sqrt{27.6} \approx 5.25 \text{ lpm}$$

- b) Los pacientes presentan frecuencias cardíacas que se desvían en promedio **5.25 lpm** respecto a la media de 72 lpm. Esta dispersión es relativamente baja, lo que sugiere un grupo clínicamente homogéneo en cuanto a su estado cardiovascular basal.

```
# FC de 6 pacientes
fc <- c(68, 72, 75, 80, 72, 65)
cat("Datos ordenados:", sort(fc), "\n")

## Datos ordenados: 65 68 72 72 75 80
cat("Rango:", diff(range(fc)), "lpm\n")

## Rango: 15 lpm
cat("Media:", mean(fc), "lpm\n")
```

```
## Media: 72 lpm
cat("Varianza muestral:", round(var(fc), 2), "lpm^2\n")

## Varianza muestral: 27.6 lpm^2
cat("Desviación estándar:", round(sd(fc), 4), "lpm\n")

## Desviación estándar: 5.2536 lpm
# Tabla de cálculo manual
df_fc <- data.frame(
  x_i      = sort(fc),
  desv     = sort(fc) - mean(fc),
  desv_cuad = (sort(fc) - mean(fc))^2
)
knitr::kable(df_fc, col.names = c("x_i", "x_i -  $\bar{x}$ ", "(x_i -  $\bar{x}$ )^2"),
  caption = "Cálculo manual de varianza: FC en rehabilitación cardíaca")
```

Table 9: Cálculo manual de varianza: FC en rehabilitación cardíaca

x_i	$x_i - \bar{x}$	$(x_i - \bar{x})^2$
65	-7	49
68	-4	16
72	0	0
72	0	0
75	3	9
80	8	64

3.2 Ejercicio 13

En un estudio comparativo se midió la **presión arterial sistólica** (PAS en mmHg) en dos grupos de pacientes:

- **Grupo A** (dieta DASH): 115, 120, 118, 122, 119, 117, 121, 120
 - **Grupo B** (sin intervención): 105, 130, 112, 138, 125, 108, 135, 127
- a) Calcule la media y desviación estándar de cada grupo.
b) ¿Cuál grupo tiene mayor dispersión? ¿Qué implica clínicamente?

Solución:

```
# PAS en dos grupos
grupo_a <- c(115, 120, 118, 122, 119, 117, 121, 120)
grupo_b <- c(105, 130, 112, 138, 125, 108, 135, 127)

cat("=== Grupo A (dieta DASH) ===\n")

## === Grupo A (dieta DASH) ===
cat("Media:", round(mean(grupo_a), 2), "mmHg\n")

## Media: 119 mmHg
cat("DE:    ", round(sd(grupo_a), 2), "mmHg\n")

## DE:      2.27 mmHg
```

```
cat("Rango:", diff(range(grupo_a)), "mmHg\n\n")
```

```
## Rango: 7 mmHg
```

```
cat("=== Grupo B (sin intervención) ===\n")
```

```
## === Grupo B (sin intervención) ===
```

```
cat("Media:", round(mean(grupo_b), 2), "mmHg\n")
```

```
## Media: 122.5 mmHg
```

```
cat("DE:    ", round(sd(grupo_b), 2), "mmHg\n")
```

```
## DE:      12.57 mmHg
```

```
cat("Rango:", diff(range(grupo_b)), "mmHg\n")
```

```
## Rango: 33 mmHg
```

El Grupo B tiene mayor dispersión (DE 13 mmHg vs 2.1 mmHg). Clínicamente, esto indica que los pacientes sin intervención muestran **mayor variabilidad en el control de la presión**, lo que dificulta el manejo clínico y aumenta el riesgo de eventos cardiovasculares. El Grupo A con dieta DASH presenta valores más homogéneos alrededor de una media similar.

3.3 Ejercicio 14

Calcule e interprete el **coeficiente de variación (CV)** para las siguientes medidas clínicas:

Variable	Media	Desviación estándar
Temperatura (°C)	37.2	0.5
FC en reposo (lpm)	76	12
SpO ₂ (%)	95	3
6MWT (m)	320	85

- Calcule el CV para cada variable.
- ¿Cuál variable presenta mayor variabilidad relativa?
- ¿Por qué es importante el CV cuando se comparan variables con distintas unidades?

Solución:

$$CV = \frac{s}{\bar{x}} \times 100\%$$

```
# Datos de las cuatro variables
variables <- c("Temperatura (°C)", "FC reposo (lpm)", "SpO2 (%)", "6MWT (m)")
medias    <- c(37.2, 76, 95, 320)
des_est   <- c(0.5, 12, 3, 85)

cv <- (des_est / medias) * 100

df_cv <- data.frame(Variable = variables, Media = medias,
                    DE = des_est, CV_pct = round(cv, 2))
knitr::kable(df_cv, col.names = c("Variable", "Media", "DE", "CV (%)"),
              caption = "Coeficiente de variación de variables clínicas")
```

Table 11: Coeficiente de variación de variables clínicas

Variable	Media	DE	CV (%)
Temperatura (°C)	37.2	0.5	1.34
FC reposo (lpm)	76.0	12.0	15.79
SpO2 (%)	95.0	3.0	3.16
6MWT (m)	320.0	85.0	26.56

- b) La variable con **mayor variabilidad relativa** es la **6MWT** (CV 26.6%), seguida de la **FC en reposo** (CV 15.8%). La temperatura es extremadamente estable (CV 1.3%).
- c) El CV permite comparar la variabilidad entre variables con distintas unidades o escalas (no se puede comparar directamente 0.5°C con 85 m). Al expresar la dispersión como porcentaje de la media, elimina el efecto de la escala, permitiendo comparaciones significativas.

3.4 Ejercicio 15

Un fisioterapeuta desea saber si el **nivel de dolor** (EVA, 0–10) o la **capacidad funcional** (escala FIM, 18–126) varía más entre sus pacientes con lesión medular. Los datos de 8 pacientes son:

Paciente	EVA	FIM
1	7	45
2	5	78
3	8	32
4	3	95
5	6	60
6	4	88
7	9	25
8	5	72

- a) Calcule el CV para cada variable.
- b) ¿Con base en el CV, cuál variable tiene mayor variabilidad relativa?
- c) ¿Tiene sentido comparar las desviaciones estándar directamente? Explique.

Solución:

```
# Datos de 8 pacientes
eva_pac <- c(7, 5, 8, 3, 6, 4, 9, 5)
fim_pac <- c(45, 78, 32, 95, 60, 88, 25, 72)

cat("=== Escala EVA ===\n")

## === Escala EVA ===
cat("Media:", round(mean(eva_pac), 2), "\n")

## Media: 5.88
cat("DE:", round(sd(eva_pac), 2), "\n")

## DE: 2.03
cat("CV:", round(sd(eva_pac)/mean(eva_pac)*100, 1), "%\n\n")

## CV: 34.6 %
```

```
cat("=== Escala FIM ===\n")

## === Escala FIM ===
cat("Media:", round(mean(fim_pac), 2), "\n")

## Media: 61.88
cat("DE:", round(sd(fim_pac), 2), "\n")

## DE: 25.86
cat("CV:", round(sd(fim_pac)/mean(fim_pac)*100, 1), "%\n")

## CV: 41.8 %
```

- c) No tiene sentido comparar directamente las DE (2.27 puntos EVA vs 26.3 puntos FIM) porque están en escalas completamente diferentes (0–10 vs 18–126). El CV sí permite la comparación al estandarizar la dispersión respecto a la media.

3.5 Ejercicio 16

Un estudio multicéntrico comparó el **tiempo de recuperación** (días) de dos procedimientos de rehabilitación en pacientes con LCA (ligamento cruzado anterior):

- **Procedimiento estándar** ($n = 12$): media = 85 días, DE = 22 días
 - **Nuevo protocolo** ($n = 12$): media = 70 días, DE = 18 días
- a) Calcule el CV para cada procedimiento.
b) ¿Cuál tiene mayor variabilidad relativa?
c) Si usted fuera el clínico que decide qué protocolo implementar, ¿qué información adicional necesitaría para tomar la decisión? ¿Solo la media es suficiente?

Solución:

a) $CV_{\text{estándar}} = \frac{22}{85} \times 100 = 25.9\%$
 $CV_{\text{nuevo}} = \frac{18}{70} \times 100 = 25.7\%$

```
# Comparación de protocolos
cat("Procedimiento estándar:\n")

## Procedimiento estándar:
cat("  Media:", 85, "días | DE:", 22, "días\n")

##   Media: 85 días | DE: 22 días
cat("  CV:", round(22/85*100, 1), "%\n\n")

##   CV: 25.9 %
cat("Nuevo protocolo:\n")

## Nuevo protocolo:
cat("  Media:", 70, "días | DE:", 18, "días\n")

##   Media: 70 días | DE: 18 días
cat("  CV:", round(18/70*100, 1), "%\n")

##   CV: 25.7 %
```

- b) Ambos tienen variabilidad relativa muy similar (~26%), por lo que la dispersión relativa no es determinante.
- c) Solo la media no es suficiente. Se necesita:
- Significancia estadística de la diferencia (prueba de hipótesis)
 - Valores mínimos y máximos (rango)
 - Tasas de complicaciones y eventos adversos
 - Costo-efectividad del nuevo protocolo
 - Calidad de vida de los pacientes durante la recuperación
 - Si hay interacción con características del paciente (edad, comorbilidades)
-

3.6 Ejercicio 17

Los siguientes datos corresponden a la **saturación de oxígeno** (SpO₂, %) de 10 pacientes con EPOC exacerbado al momento del ingreso a urgencias:

78, 82, 85, 79, 88, 83, 80, 84, 81, 86

- a) Calcule manualmente: media, varianza y desviación estándar.
- b) ¿Qué porcentaje de los pacientes tiene SpO₂ dentro de $\bar{x} \pm s$? ¿Y dentro de $\bar{x} \pm 2s$?
- c) Grafique los datos con una línea horizontal en la media.

Solución:

a) $\bar{x} = \frac{78+82+85+79+88+83+80+84+81+86}{10} = \frac{826}{10} = 82.6\%$

```
# SpO2 en EPOC exacerbado
spo2 <- c(78, 82, 85, 79, 88, 83, 80, 84, 81, 86)
n <- length(spo2)
x_bar <- mean(spo2)
s2 <- var(spo2) # varianza muestral
s <- sd(spo2)

cat("Media:", x_bar, "%\n")

## Media: 82.6 %

cat("Varianza muestral:", round(s2, 4), "%\n")

## Varianza muestral: 10.2667

cat("Desviación estándar:", round(s, 4), "%\n\n")

## Desviación estándar: 3.2042

# Proporción dentro de +/- 1s y +/- 2s
dentro_1s <- mean(spo2 >= x_bar - s & spo2 <= x_bar + s) * 100
dentro_2s <- mean(spo2 >= x_bar - 2*s & spo2 <= x_bar + 2*s) * 100
cat("Intervalo  $\bar{x} \pm s$ : [", round(x_bar-s,1), ",", round(x_bar+s,1), "]\n")

## Intervalo  $\bar{x} \pm s$ : [ 79.4 , 85.8 ]

cat("Pacientes dentro de  $\bar{x} \pm s$ :", dentro_1s, "%\n\n")

## Pacientes dentro de  $\bar{x} \pm s$ : 60 %

cat("Intervalo  $\bar{x} \pm 2s$ : [", round(x_bar-2*s,1), ",", round(x_bar+2*s,1), "]\n")


## Intervalo  $\bar{x} \pm 2s$ : [ 76.2 , 89 ]
```



```
cat("Pacientes dentro de  $\bar{x} \pm 2s$ :", dentro_2s, "%\n")

## Pacientes dentro de  $\bar{x} \pm 2s$ : 100 %

df_spo2 <- data.frame(paciente = 1:10, spo2 = spo2)
ggplot(df_spo2, aes(x = paciente, y = spo2)) +
  geom_point(size = 3, color = "#1565C0") +
  geom_hline(yintercept = x_bar, color = "#C62828", linetype = "dashed", linewidth = 1) +
  geom_hline(yintercept = c(x_bar - s, x_bar + s),
    color = "#FFA726", linetype = "dotted", linewidth = 0.8) +
  annotate("text", x = 10.5, y = x_bar + 0.3,
    label = paste0(" $\bar{x}$ =", x_bar), color = "#C62828", size = 3.5) +
  labs(x = "Paciente", y = "SpO2 (%)",
    title = "SpO2 en EPOC exacerbado - Pacientes al ingreso") +
  scale_x_continuous(breaks = 1:10) +
  theme_minimal()
```



3.7 Ejercicio 18

Discuta la elección de la medida de dispersión apropiada para las siguientes situaciones clínicas. Justifique si usaría **rango**, **varianza**, **desviación estándar** o **coeficiente de variación**:

- Reportar la variabilidad del IMC en un artículo científico junto con la media.
- Comparar la variabilidad de la glucemia entre pacientes pediátricos (media 90 mg/dL) y adultos mayores (media 115 mg/dL).
- Describir rápidamente el spread de frecuencias cardíacas en una tabla de urgencias.
- Analizar si un nuevo glucómetro es más preciso que el estándar.

Solución:

Situación	Medida preferida	Justificación
a) Reporte IMC en artículo	Desviación estándar	Misma unidad que la media, fácil de interpretar; reportar como $\bar{x} \pm s$ o como tabla
b) Comparar glucemia pediátrica vs adultos	Coefficiente de variación (CV)	Medias diferentes (90 vs 115 mg/dL); el CV elimina el efecto de la escala
c) FC en urgencias (tabla rápida)	Rango	Rápido de calcular, da idea inmediata del spread; útil para reportes operativos
d) Precisión de glucómetro	Varianza o DE	Se mide la dispersión de mediciones repetidas del mismo valor; menor DE = mayor precisión

3.8 Ejercicio 19

Se analizó el número de **días de hospitalización** de 30 pacientes con fracturas de cadera intervenidas quirúrgicamente. La estadística descriptiva arrojó: $\bar{x} = 8.4$ días, mediana = 7 días, $s = 4.2$ días, $s^2 = 17.64$ días², rango = 18 días, $Q_1 = 5$ días, $Q_3 = 11$ días.

- Calcule el **coeficiente de variación**.
- Calcule el **rango intercuartílico (RIC)**.
- ¿Cuál medida de dispersión (DE o RIC) es más apropiada para este conjunto de datos? Justifique usando la relación entre media y mediana.

Solución:

a) $CV = \frac{s}{\bar{x}} \times 100 = \frac{4.2}{8.4} \times 100 = 50\%$

La alta variabilidad indica heterogeneidad importante en los tiempos de hospitalización.

b) $RIC = Q_3 - Q_1 = 11 - 5 = 6$ días

- c) Como $\bar{x} = 8.4 > \text{mediana} = 7$, la distribución presenta **sesgo a la derecha** (probablemente algunas hospitalizaciones muy prolongadas). En este caso, el **RIC es más apropiado** que la DE, ya que el RIC es robusto frente a valores extremos y describe mejor la variabilidad del 50% central de los datos. La DE es influenciada por los valores extremos que generan el sesgo.

```
# Verificación con estadísticos dados
media <- 8.4
mediana <- 7
```

```

s      <- 4.2
Q1     <- 5
Q3     <- 11

CV <- s / media * 100
RIC <- Q3 - Q1

cat("Coeficiente de variación:", CV, "%\n")

## Coeficiente de variación: 50 %
cat("Rango intercuartílico (RIC):", RIC, "días\n")

## Rango intercuartílico (RIC): 6 días
cat("Media > Mediana:", media, ">", mediana, "-> sesgo a la derecha\n")

## Media > Mediana: 8.4 > 7 -> sesgo a la derecha
cat("Recomendación: usar mediana y RIC para describir la distribución\n")

## Recomendación: usar mediana y RIC para describir la distribución

```

4 Medidas de Posición

4.1 Ejercicio 20

Los tiempos de espera (en minutos) de **8 pacientes** en la sala de urgencias fueron:

8, 12, 15, 18, 20, 22, 28, 30

- Calcule manualmente Q_1 , Q_2 (mediana), Q_3 y el **rango intercuartílico (RIC)**.
- Interprete cada cuartil en el contexto del tiempo de espera.
- Verifique con R.

Solución:

- Datos ordenados: 8, 12, 15, 18, 20, 22, 28, 30 ($n = 8$)

Mediana (Q_2): Promedio de posiciones 4 y 5: $\frac{18+20}{2} = 19$ min

Q_1 : Mediana de la mitad inferior {8, 12, 15, 18}: $\frac{12+15}{2} = 13.5$ min

Q_3 : Mediana de la mitad superior {20, 22, 28, 30}: $\frac{22+28}{2} = 25$ min

RIC: $Q_3 - Q_1 = 25 - 13.5 = 11.5$ min

- Interpretación:

- $Q_1 = 13.5$ min: el 25% de los pacientes espera menos de 13.5 minutos.
- $Q_2 = 19$ min: el 50% espera menos de 19 minutos (tiempo típico de espera).
- $Q_3 = 25$ min: el 75% espera menos de 25 minutos; el 25% espera más.
- $RIC = 11.5$ min: el 50% central de los pacientes espera entre 13.5 y 25 minutos.

```

# Tiempos de espera
t_espera <- c(8, 12, 15, 18, 20, 22, 28, 30)
cat("Datos:", t_espera, "\n")

```

```
## Datos: 8 12 15 18 20 22 28 30
```

```

cat("Q1 (P25):", quantile(t_espera, 0.25), "min\n")

## Q1 (P25): 14.25 min
cat("Q2 (mediana):", quantile(t_espera, 0.50), "min\n")

## Q2 (mediana): 19 min
cat("Q3 (P75):", quantile(t_espera, 0.75), "min\n")

## Q3 (P75): 23.5 min
cat("RIC = Q3 - Q1:", IQR(t_espera), "min\n")

## RIC = Q3 - Q1: 9.25 min
# Resumen completo
cat("\nResumen estadístico completo:\n")

##
## Resumen estadístico completo:
print(summary(t_espera))

```

```

##      Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
##      8.00  14.25   19.00   19.12  23.50   30.00

```

4.2 Ejercicio 21

Se registró el **puntaje de dolor EVA** (0–10) de 12 pacientes en rehabilitación postoperatoria de rodilla a las 48 horas. Los datos son:

3, 5, 2, 7, 4, 6, 5, 3, 8, 4, 5, 6

- Calcule Q_1 , Q_2 , Q_3 y el RIC.
- Calcule el **percentil 30** y el **percentil 85**.
- Interprete el percentil 85 en términos clínicos.

Solución:

```

# Dolor EVA en rehabilitación postoperatoria
eva_post <- c(3, 5, 2, 7, 4, 6, 5, 3, 8, 4, 5, 6)
eva_ord  <- sort(eva_post)
cat("Datos ordenados:", eva_ord, "\n\n")

```

```
## Datos ordenados: 2 3 3 4 4 5 5 5 6 6 7 8
```

```

# Cuartiles y RIC
cat("Q1:", quantile(eva_post, 0.25), "\n")

```

```
## Q1: 3.75
```

```
cat("Q2 (mediana):", median(eva_post), "\n")
```

```
## Q2 (mediana): 5
```

```
cat("Q3:", quantile(eva_post, 0.75), "\n")
```

```
## Q3: 6
```

```
cat("RIC:", IQR(eva_post), "\n\n")

## RIC: 2.25

# Percentiles
cat("Percentil 30:", quantile(eva_post, 0.30), "\n")

## Percentil 30: 4

cat("Percentil 85:", quantile(eva_post, 0.85), "\n")

## Percentil 85: 6.35
```

- c) Un percentil 85 de ~6.55 indica que el **85% de los pacientes** en recuperación postoperatoria de rodilla reporta un dolor EVA por debajo de 6.55 puntos (dolor moderado) a las 48 horas. Solo el 15% experimenta dolor de alta intensidad ($EVA > 6.55$). Esto puede usarse para evaluar la efectividad del protocolo de analgesia: si el objetivo es que el 90% tenga $EVA < 7$, el protocolo actual está cerca de lograrlo.

4.3 Ejercicio 22

Un programa de rehabilitación cardíaca evaluó la **distancia en la prueba de 6MWT** (metros) de 25 pacientes. Los cuartiles fueron: $Q_1 = 250$ m, $Q_2 = 310$ m, $Q_3 = 380$ m.

- Construya un **diagrama de cajas (boxplot) esquemático** describiendo cada componente.
- Calcule el RIC e interprete.
- Si la distancia mínima fue 180 m y la máxima fue 520 m, ¿hay indicios de valores atípicos? Use el criterio de Tukey (vallas) como aproximación.

Solución:

- Componentes del boxplot:
 - Caja:** del $Q_1 = 250$ al $Q_3 = 380$ m (contiene el 50% central)
 - Línea central:** $Q_2 = 310$ m (mediana)
 - Bigotes:** se extienden hasta los valores observados dentro de las vallas de Tukey
 - Puntos fuera de las vallas:** valores atípicos
- $RIC = Q_3 - Q_1 = 380 - 250 = 130$ m. El 50% central de los pacientes recorre entre 250 y 380 m en la prueba de 6 minutos.
- Criterio de Tukey:**
 - Valla inferior: $Q_1 - 1.5 \times RIC = 250 - 1.5(130) = 250 - 195 = 55$ m
 - Valla superior: $Q_3 + 1.5 \times RIC = 380 + 1.5(130) = 380 + 195 = 575$ m

Como $180 > 55$ y $520 < 575$, **no hay valores atípicos** según el criterio de Tukey.

```
# Cálculo de vallas de Tukey
Q1 <- 250; Q3 <- 380
RIC <- Q3 - Q1
valla_inf <- Q1 - 1.5 * RIC
valla_sup <- Q3 + 1.5 * RIC

cat("RIC:", RIC, "m\n")

## RIC: 130 m

cat("Valla inferior (Q1 - 1.5·RIC):", valla_inf, "m\n")
```

```
## Valla inferior (Q1 - 1.5·RIC): 55 m
cat("Valla superior (Q3 + 1.5·RIC):", valla_sup, "m\n\n")

## Valla superior (Q3 + 1.5·RIC): 575 m
cat("Mínimo observado:", 180, "m -> ¿Atípico?", 180 < valla_inf, "\n")

## Mínimo observado: 180 m -> ¿Atípico? FALSE
cat("Máximo observado:", 520, "m -> ¿Atípico?", 520 > valla_sup, "\n")

## Máximo observado: 520 m -> ¿Atípico? FALSE
```

4.4 Ejercicio 23

Se registró el **tiempo de hospitalización** (días) de 20 pacientes con EPOC exacerbado. Use R para calcular cuartiles y construir el boxplot.

```
# Simulación de datos de hospitalización en EPOC
set.seed(123)
dias_hosp <- c(3, 5, 4, 6, 7, 5, 8, 4, 9, 6,
               5, 7, 4, 6, 8, 5, 10, 4, 6, 7)

cat("=== Estadística de posición ===\n")

## === Estadística de posición ===
cat("Mínimo:", min(dias_hosp), "días\n")

## Mínimo: 3 días
cat("Q1:", quantile(dias_hosp, 0.25), "días\n")

## Q1: 4.75 días
cat("Mediana:", median(dias_hosp), "días\n")

## Mediana: 6 días
cat("Media:", mean(dias_hosp), "días\n")

## Media: 5.95 días
cat("Q3:", quantile(dias_hosp, 0.75), "días\n")


## Q3: 7 días
cat("Máximo:", max(dias_hosp), "días\n")

## Máximo: 10 días
cat("RIC:", IQR(dias_hosp), "días\n")

## RIC: 2.25 días

df_dias <- data.frame(dias = dias_hosp, grupo = "EPOC exacerbado")
ggplot(df_dias, aes(x = grupo, y = dias)) +
  geom_boxplot(fill = "#42A5F5", color = "#1565C0", alpha = 0.8, width = 0.4,
               outlier.color = "#C62828", outlier.size = 3) +
  geom_jitter(width = 0.1, alpha = 0.5, color = "#1A237E") +
```

```
labs(x = "", y = "Días de hospitalización",
     title = "Hospitalización en EPOC exacerbado",
     caption = "Puntos: valores individuales | Caja: Q1-Q3 | Línea: mediana") +
theme_minimal()
```



4.5 Ejercicio 24

En un programa de fisioterapia respiratoria se midió el **volumen espiratorio forzado en 1 segundo (VEF)**, expresado como porcentaje del predicho, en 30 pacientes con EPOC. Los cuantiles calculados son:

$$P_{10} = 38, \quad P_{25} = 45, \quad P_{50} = 55, \quad P_{75} = 65, \quad P_{90} = 72$$

- Interprete cada uno de estos percentiles.
- ¿Qué proporción de pacientes tiene $VEF > 65\%$?
- ¿Qué proporción tiene VEF entre 38% y 72%?

Solución:

- Interpretación:
 - $P_{10} = 38\%$: el 10% de los pacientes tiene VEF menor al 38% del predicho (EPOC muy severo).
 - $P_{25} = 45\%$: el 25% tiene VEF < 45% del predicho.
 - $P_{50} = 55\%$: el 50% de los pacientes (valor típico) tiene VEF = 55% del predicho (EPOC moderado, estadio II de GOLD).
 - $P_{75} = 65\%$: el 75% tiene VEF < 65%; solo el 25% supera este valor.
 - $P_{90} = 72\%$: el 90% tiene VEF < 72%; el 10% tiene función conservada (EPOC leve).
- $P(VEF_1 > 65\%) = 1 - P_{75} = 1 - 0.75 = \mathbf{25\%}$
- $P(38\% \leq VEF_1 \leq 72\%) = P_{90} - P_{10} = 0.90 - 0.10 = \mathbf{80\%}$ (rango intercuantílico 10-90)

4.6 Ejercicio 25

Se registró el **índice de masa corporal (IMC)** de 40 pacientes en un programa de rehabilitación cardiovascular. Calcule e interprete en R:

```
# IMC de 40 pacientes en rehabilitación cardiovascular
set.seed(42)
imc_rehab <- round(c(
  25.3, 28.7, 31.2, 27.8, 33.5, 29.1, 26.4, 35.8, 30.2, 28.5,
  32.1, 27.3, 29.8, 34.2, 26.9, 31.7, 28.3, 30.6, 27.1, 33.9,
  29.4, 26.7, 32.8, 28.1, 30.9, 27.6, 35.1, 29.7, 31.4, 28.9,
  26.2, 33.3, 27.9, 30.1, 29.2, 28.6, 32.5, 31.8, 27.4, 30.7
), 1)

# Estadísticas de posición
cat("=== Medidas de posición: IMC ===\n")

## === Medidas de posición: IMC ===
cat("Mínimo:", min(imc_rehab), "kg/m²\n")

## Mínimo: 25.3 kg/m²
cuartiles <- quantile(imc_rehab)
print(cuartiles)

##      0%      25%      50%      75%     100%
## 25.300 27.875 29.550 31.725 35.800
cat("Máximo:", max(imc_rehab), "kg/m²\n")

## Máximo: 35.8 kg/m²
cat("RIC:", IQR(imc_rehab), "kg/m²\n")

## RIC: 3.85 kg/m²
# Percentiles específicos
cat("\nPercentil 10:", quantile(imc_rehab, 0.10), "kg/m²\n")

##
## Percentil 10: 26.88 kg/m²
cat("Percentil 90:", quantile(imc_rehab, 0.90), "kg/m²\n")

## Percentil 90: 33.54 kg/m²
# ¿Cuántos pacientes tienen IMC >= 30 (obesidad)?
cat("\nProporción con obesidad (IMC >= 30):",
    round(mean(imc_rehab >= 30)*100, 1), "%\n")

##
## Proporción con obesidad (IMC >= 30): 45 %
```

4.7 Ejercicio 26

Use R para comparar los **boxplots** de la frecuencia cardíaca (FC en reposo) en tres grupos de pacientes con diferente clasificación de HTA según la guía ACC/AHA 2017:



```

# FC en reposo según clasificación HTA
set.seed(2024)
normal_pa <- round(rnorm(20, mean = 70, sd = 8))
elevada <- round(rnorm(20, mean = 74, sd = 9))
hta_1 <- round(rnorm(20, mean = 80, sd = 10))

df_hta <- data.frame(
  FC = c(normal_pa, elevada, hta_1),
  Grupo = rep(c("Normal\n(<120/80)", "Elevada\n(120-129/<80)", "HTA I\n(130-139/80-89)"),
    each = 20)
)

ggplot(df_hta, aes(x = Grupo, y = FC, fill = Grupo)) +
  geom_boxplot(alpha = 0.75, outlier.color = "#C62828", outlier.size = 2) +
  geom_jitter(width = 0.15, alpha = 0.4, size = 1.5) +
  scale_fill_manual(values = c("#66BB6A", "#FFA726", "#EF5350"), guide = "none") +
  labs(x = "Clasificación de presión arterial", y = "FC en reposo (lpm)",
    title = "Frecuencia cardíaca en reposo según clasificación de HTA") +
  theme_minimal()

```



```

# Estadísticas por grupo
cat("\nResumen estadístico por grupo:\n")

```

```

##
## Resumen estadístico por grupo:

```

```

df_hta %>%
  group_by(Grupo) %>%
  summarise(
    Media = round(mean(FC), 1),
    Mediana = median(FC),

```

```

Q1 = quantile(FC, 0.25),
Q3 = quantile(FC, 0.75),
RIC = IQR(FC)
) %>%
knitr::kable(caption = "FC en reposo por clasificación de HTA")

```

Table 14: FC en reposo por clasificación de HTA

Grupo	Media	Mediana	Q1	Q3	RIC
Elevada (120-129/<80)	73.2	73	69.75	78.00	8.25
HTA I (130-139/80-89)	80.3	80	72.75	86.25	13.50
Normal (<120/80)	67.7	69	60.75	74.00	13.25

5 Datos Atípicos: Criterio de Tukey

5.1 Ejercicio 27

Usando los datos de tiempos de espera del Ejercicio 20: 8, 12, 15, 18, 20, 22, 28, 30 minutos, donde $Q_1 = 13.5$, $Q_3 = 25$, $RIC = 11.5$:

- Calcule las **vallas de Tukey** (inferior y superior).
- Identifique si existe algún valor atípico.
- ¿Qué ocurre si un noveno paciente espera **58 minutos**? ¿Es un dato atípico?

Solución:

- Vallas de Tukey:**

$$\text{Valla inferior} = Q_1 - 1.5 \times RIC = 13.5 - 1.5(11.5) = 13.5 - 17.25 = -3.75 \text{ min}$$

$$\text{Valla superior} = Q_3 + 1.5 \times RIC = 25 + 1.5(11.5) = 25 + 17.25 = 42.25 \text{ min}$$

- Todos los valores originales (8 a 30 min) están dentro del intervalo $[-3.75, 42.25]$. **No hay datos atípicos** en el conjunto original.
- El valor 58 min > 42.25 min (valla superior), por lo tanto **es un dato atípico** según el criterio de Tukey.

```

# Tiempos de espera y criterio de Tukey
t_espera <- c(8, 12, 15, 18, 20, 22, 28, 30)

Q1 <- quantile(t_espera, 0.25)
Q3 <- quantile(t_espera, 0.75)
RIC <- IQR(t_espera)

valla_inf <- Q1 - 1.5 * RIC
valla_sup <- Q3 + 1.5 * RIC

cat("Q1:", Q1, "| Q3:", Q3, "| RIC:", RIC, "\n")

```

```
## Q1: 14.25 | Q3: 23.5 | RIC: 9.25
cat("Valla inferior:", valla_inf, "min\n")

## Valla inferior: 0.375 min
cat("Valla superior:", valla_sup, "min\n\n")

## Valla superior: 37.375 min
# Identificación de atípicos
cat("Datos atípicos en el conjunto original:\n")

## Datos atípicos en el conjunto original:
atipicos <- t_espera[t_espera < valla_inf | t_espera > valla_sup]
if(length(atipicos) == 0) {
  cat(" Ninguno\n\n")
} else {
  cat(" ", atipicos, "\n\n")
}

## Ninguno
# Verificar si 58 es atípico
nuevo_valor <- 58
cat("¿Es 58 min un dato atípico?", nuevo_valor > valla_sup, "\n")

## ¿Es 58 min un dato atípico? TRUE
cat("58 >", valla_sup, "(valla superior) =", nuevo_valor > valla_sup, "\n")

## 58 > 37.375 (valla superior) = TRUE
```


5.2 Ejercicio 28

El siguiente conjunto de datos corresponde al **número de caídas** de pacientes por mes en tres salas de un hospital (sala A, B y C). Use R para detectar datos atípicos en cada sala.

```
# Caídas mensuales por sala
set.seed(101)
sala_a <- c(1, 2, 1, 3, 2, 1, 2, 2, 1, 3, 2, 1)
sala_b <- c(0, 1, 2, 1, 0, 2, 1, 1, 8, 0, 1, 2) # valor 8: posible atípico
sala_c <- c(3, 4, 3, 5, 4, 3, 4, 4, 3, 5, 3, 4)

df_caidas <- data.frame(
  caidas = c(sala_a, sala_b, sala_c),
  sala = rep(c("Sala A", "Sala B", "Sala C"), each = 12)
)

# Boxplot para detectar atípicos
ggplot(df_caidas, aes(x = sala, y = caidas, fill = sala)) +
  geom_boxplot(alpha = 0.75, outlier.color = "#C62828", outlier.size = 3) +
  scale_fill_manual(values = c("#42A5F5", "#66BB6A", "#FFA726"), guide = "none") +
  labs(x = "Sala", y = "Caídas por mes",
       title = "Caídas de pacientes por sala hospitalaria",
       caption = "Puntos rojos = posibles datos atípicos (criterio de Tukey)") +
  theme_minimal()
```



```
# Detección de atípicos por sala
detectar_atipicos <- function(x, nombre) {
  Q1 <- quantile(x, 0.25); Q3 <- quantile(x, 0.75); RIC <- IQR(x)
  vi <- Q1 - 1.5*RIC; vs <- Q3 + 1.5*RIC
  atip <- x[x < vi | x > vs]
  cat(nombre, "-> Valla:", vi, "a", vs,
      "| Atípicos:", if(length(atip)==0) "ninguno" else paste(atip, collapse=", "), "\n")
}

detectar_atipicos(sala_a, "Sala A")

## Sala A -> Valla: -0.5 a 3.5 | Atípicos: ninguno
detectar_atipicos(sala_b, "Sala B")

## Sala B -> Valla: -1.125 a 3.875 | Atípicos: 8
detectar_atipicos(sala_c, "Sala C")

## Sala C -> Valla: 1.5 a 5.5 | Atípicos: ninguno
```

5.3 Ejercicio 29

En la evaluación de un protocolo de analgesia, se registró la **dosis de morfina** (mg/día) administrada a 10 pacientes en UCI: 2.5, 3.0, 2.8, 3.2, 2.9, 3.1, 2.7, 3.0, 15.0, 2.8.

- Detecte el dato atípico usando el criterio de Tukey.
- Calcule la media **con** y **sin** el dato atípico.
- Desde el punto de vista clínico, ¿debe eliminarse el dato atípico? ¿O debería investigarse?

Solución:

```
# Dosis de morfina en UCI
morfina <- c(2.5, 3.0, 2.8, 3.2, 2.9, 3.1, 2.7, 3.0, 15.0, 2.8)
```

```

Q1 <- quantile(morfina, 0.25)
Q3 <- quantile(morfina, 0.75)
RIC <- IQR(morfina)
vi <- Q1 - 1.5 * RIC
vs <- Q3 + 1.5 * RIC

cat("Q1:", Q1, "| Q3:", Q3, "| RIC:", RIC, "\n")

## Q1: 2.8 | Q3: 3.075 | RIC: 0.275
cat("Valla inferior:", vi, "mg/día\n")

## Valla inferior: 2.3875 mg/día
cat("Valla superior:", vs, "mg/día\n\n")

## Valla superior: 3.4875 mg/día
atipicos <- morfina[morfina < vi | morfina > vs]
cat("Datos atípicos detectados:", atipicos, "mg/día\n\n")

## Datos atípicos detectados: 15 mg/día
# Comparación con y sin atípico
cat("Media con atípico:", round(mean(morfina), 3), "mg/día\n")

## Media con atípico: 4.1 mg/día
cat("Media sin atípico:", round(mean(morfina[morfina <= vs]), 3), "mg/día\n")

## Media sin atípico: 2.889 mg/día
cat("Mediana (robusta):", median(morfina), "mg/día\n")

## Mediana (robusta): 2.95 mg/día

```

- c) **No se debe eliminar automáticamente.** En UCI, una dosis de 15 mg/día de morfina puede ser real en pacientes con dolor severo, tolerancia o intubación. Lo correcto es **investigar el origen**: revisar la historia clínica, verificar si fue un error de transcripción o dosis, confirmar el diagnóstico del paciente. Solo se elimina si se confirma que es un error de registro. En el análisis estadístico, es buena práctica reportar resultados con y sin el valor atípico.

5.4 Ejercicio 30

Se desea evaluar el **impacto de datos atípicos** sobre diferentes medidas estadísticas. Los datos originales de la **presión arterial diastólica** (PAD en mmHg) de 12 pacientes son: 72, 75, 78, 80, 76, 74, 79, 77, 75, 78, 80, 76.

- Calcule media, mediana, DE y RIC del conjunto original.
- Agregue el valor atípico $PAD = 130$ mmHg y recalcule todas las medidas.
- ¿Cuáles medidas son más robustas? Construya una tabla comparativa.

Solución:

```

# PAD original
pad_orig <- c(72, 75, 78, 80, 76, 74, 79, 77, 75, 78, 80, 76)
pad_atip <- c(pad_orig, 130)

# Función de resumen
resumen_est <- function(x) {

```

```

c(Media = round(mean(x), 2),
  Mediana = median(x),
  DE = round(sd(x), 2),
  RIC = IQR(x))
}

df_comp <- rbind(
  "Sin atípico (n=12)" = resumen_est(pad_orig),
  "Con atípico (n=13)" = resumen_est(pad_atip)
)

knitr::kable(as.data.frame(df_comp),
  caption = "Impacto del dato atípico (PAD=130 mmHg) sobre medidas estadísticas")

```

Table 15: Impacto del dato atípico (PAD=130 mmHg) sobre medidas estadísticas

	Media	Mediana	DE	RIC
Sin atípico (n=12)	76.67	76.5	2.46	3.25
Con atípico (n=13)	80.77	77.0	14.98	4.00

```

cat("\nCambio en media:", round(mean(pad_atip) - mean(pad_orig), 2), "mmHg\n")

##
## Cambio en media: 4.1 mmHg

cat("Cambio en mediana:", median(pad_atip) - median(pad_orig), "mmHg\n")

## Cambio en mediana: 0.5 mmHg

cat("Cambio en DE:", round(sd(pad_atip) - sd(pad_orig), 2), "mmHg\n")

## Cambio en DE: 12.52 mmHg

cat("Cambio en RIC:", IQR(pad_atip) - IQR(pad_orig), "mmHg\n")

## Cambio en RIC: 0.75 mmHg

```

Las medidas **robustas** (mediana y RIC) cambian poco con el dato atípico, mientras que la media y la DE son muy sensibles. Esto justifica usar mediana y RIC cuando hay datos atípicos.

6 Tablas de Contingencia y Perfiles

6.1 Ejercicio 31

En un estudio de prevalencia de HTA en una clínica de medicina interna, se evaluaron **60 pacientes**. Los resultados fueron:

- **35 hombres:** 18 con HTA y 17 sin HTA
 - **25 mujeres:** 12 con HTA y 13 sin HTA
- a) Construya la tabla de contingencia 2×2 completa con totales marginales.
 - b) Calcule los **perfiles fila** (distribución de HTA dentro de cada sexo).
 - c) Calcule los **perfiles columna** (distribución de sexo dentro de cada categoría de HTA).
 - d) ¿Existen diferencias en la prevalencia de HTA entre hombres y mujeres?

Solución:

a) Tabla de contingencia:

	HTA: Sí	HTA: No	Total
Hombre	18	17	35
Mujer	12	13	25
Total	30	30	60

b) **Perfiles fila** (% dentro de cada sexo):

	HTA: Sí	HTA: No	Total
Hombre	51.4%	48.6%	100%
Mujer	48.0%	52.0%	100%

c) **Perfiles columna** (% dentro de cada categoría de HTA):

	HTA: Sí	HTA: No
Hombre	60.0%	56.7%
Mujer	40.0%	43.3%
Total	100%	100%

d) La prevalencia de HTA es 51.4% en hombres vs 48.0% en mujeres. La diferencia es pequeña (3.4 pp) y probablemente no sea estadísticamente significativa en esta muestra de 60 pacientes. Se requeriría una prueba chi-cuadrado para confirmarlo.

```
# Tabla de contingencia HTA por sexo
tabla_hta <- matrix(c(18, 17, 12, 13), nrow = 2, byrow = TRUE,
                    dimnames = list(Sexo = c("Hombre", "Mujer"),
                                    HTA = c("Si", "No")))

cat("=== Tabla de contingencia ===\n")

## === Tabla de contingencia ===
print(addmargins(tabla_hta))

##           HTA
## Sexo      Si No Sum
##  Hombre  18 17  35
##  Mujer   12 13  25
##  Sum     30 30  60

cat("\n=== Perfiles fila (% por sexo) ===\n")

##
## === Perfiles fila (% por sexo) ===
perfiles_fila <- round(prop.table(tabla_hta, margin = 1) * 100, 1)
print(perfiles_fila)

##           HTA
## Sexo      Si  No
##  Hombre  51.4 48.6
##  Mujer   48.0 52.0
```

```
cat("\n=== Perfiles columna (% por HTA) ===\n")

##
## === Perfiles columna (% por HTA) ===
perfiles_col <- round(prop.table(tabla_hta, margin = 2) * 100, 1)
print(perfiles_col)

##           HTA
## Sexo      Si   No
## Hombre 60 56.7
## Mujer  40 43.3

cat("\nPrevalencia HTA: Hombres =", perfiles_fila[1,1], "% | Mujeres =", perfiles_fila[2,1], "%\n")

##
## Prevalencia HTA: Hombres = 51.4 % | Mujeres = 48 %
```

6.2 Ejercicio 32

En un hospital de tercer nivel se registró el **tipo de ingreso** (urgente vs programado) y el **resultado al egreso** (mejoría, sin cambio, complicación) de 120 pacientes con EPOC. Los datos son:

	Mejoría	Sin cambio	Complicación	Total
Urgente	35	18	22	75
Programado	28	12	5	45
Total	63	30	27	120

- Calcule los perfiles fila e interprételos clínicamente.
- ¿Qué tipo de ingreso tiene mayor proporción de complicaciones?
- Construya la tabla en R y grafique los perfiles fila.

Solución:

- Perfiles fila:

	Mejoría	Sin cambio	Complicación
Urgente	46.7%	24.0%	29.3%
Programado	62.2%	26.7%	11.1%

Los ingresos urgentes tienen mayor proporción de complicaciones (29.3% vs 11.1%) y menor tasa de mejoría (46.7% vs 62.2%), lo cual es clínicamente coherente dado que los pacientes que ingresan por urgencias suelen tener exacerbaciones más severas.

- El **ingreso urgente** tiene mayor proporción de complicaciones (29.3% vs 11.1%).

```
# Tabla EPOC: tipo ingreso vs resultado
tabla_epoc <- matrix(c(35, 18, 22, 28, 12, 5),
  nrow = 2, byrow = TRUE,
  dimnames = list(
    Ingreso = c("Urgente", "Programado"),
    Resultado = c("Mejoría", "Sin cambio", "Complicación")
  ))
```



```

cat("=== Tabla de contingencia ===\n")

## === Tabla de contingencia ===
print(addmargins(tabla_epoc))

##
##      Resultado
## Ingreso      Mejoría Sin cambio Complicación Sum
## Urgente      35      18      22 75
## Programado    28      12      5 45
## Sum          63      30      27 120

cat("\n=== Perfiles fila (%) ===\n")


##
## === Perfiles fila (%) ===
pf_epoc <- round(prop.table(tabla_epoc, 1) * 100, 1)
print(pf_epoc)

##
##      Resultado
## Ingreso      Mejoría Sin cambio Complicación
## Urgente      46.7      24.0      29.3
## Programado    62.2      26.7      11.1

# Gráfico de perfiles fila
df_epoc <- as.data.frame.table(pf_epoc)
colnames(df_epoc) <- c("Ingreso", "Resultado", "Proporcion")

ggplot(df_epoc, aes(x = Resultado, y = Proporcion, fill = Ingreso)) +
  geom_col(position = "dodge", alpha = 0.85) +
  scale_fill_manual(values = c("#1565C0", "#66BB6A")) +
  labs(x = "Resultado al egreso", y = "Proporción (%)",
       title = "Perfiles fila: resultado según tipo de ingreso en EPOC") +
  geom_text(aes(label = paste0(Proporcion, "%")),
            position = position_dodge(width = 0.9), vjust = -0.4, size = 3.5) +
  theme_minimal()

```



6.3 Ejercicio 33

En un estudio de fisioterapia de piso pélvico, se registraron el **grado de incontinencia urinaria** (leve, moderada, severa) y la **respuesta al tratamiento** (exitosa/no exitosa) en 90 pacientes mujeres:

	Exitosa	No exitosa	Total
Leve	28	7	35
Moderada	22	13	35
Severa	8	12	20

- Calcule los perfiles fila.
- ¿Existe una tendencia: a mayor severidad, menor respuesta al tratamiento?
- Use R para construir la tabla y calcular los perfiles.

Solución:

```
# Tabla: grado de incontinencia vs respuesta al tratamiento
tabla_inc <- matrix(c(28, 7, 22, 13, 8, 12),
  nrow = 3, byrow = TRUE,
  dimnames = list(
    Grado = c("Leve", "Moderada", "Severa"),
    Respuesta = c("Exitosa", "No exitosa")
  ))

cat("=== Tabla de contingencia ===\n")

## === Tabla de contingencia ===
print(addmargins(tabla_inc))
```

```
##          Respuesta
## Grado      Exitosa No exitosa Sum
##   Leve          28      7    35
##   Moderada       22     13    35
##   Severa         8      12    20
##   Sum           58     32    90
```

```
cat("\n=== Perfiles fila (%) ===\n")
```

```
##
## === Perfiles fila (%) ===
```

```
pf_inc <- round(prop.table(tabla_inc, 1) * 100, 1)
print(pf_inc)
```


```
##          Respuesta
## Grado      Exitosa No exitosa
##   Leve          80.0     20.0
##   Moderada       62.9     37.1
##   Severa         40.0     60.0
```

```
# Gráfico de barras apiladas
```

```
df_inc <- as.data.frame.table(pf_inc)
```

```
colnames(df_inc) <- c("Grado", "Respuesta", "Proporcion")
```

```
ggplot(df_inc, aes(x = Grado, y = Proporcion, fill = Respuesta)) +
  geom_col(alpha = 0.85) +
  scale_fill_manual(values = c("#1565C0", "#EF5350")) +
  geom_text(aes(label = paste0(Proporcion, "%")),
            position = position_stack(vjust = 0.5), color = "white",
            fontface = "bold", size = 4) +
  labs(x = "Grado de incontinencia", y = "Proporción (%)",
       title = "Respuesta al tratamiento de fisioterapia según grado de incontinencia") +
  theme_minimal()
```



- b) **Sí hay una tendencia clara:** la tasa de éxito disminuye con la severidad: 80% (leve) → 62.9% (moderada) → 40% (severa). A mayor severidad de la incontinencia, menor respuesta al tratamiento conservador de fisioterapia, lo que sugiere que los casos severos podrían requerir intervenciones adicionales (cirugía, biofeedback avanzado).

6.4 Ejercicio 34

Un estudiante de enfermería revisa los datos de una sala de hospitalización y construye la siguiente tabla:

Turno	Medicación correcta	Error de medicación	Total
Mañana	156	4	160
Tarde	148	7	155
Noche	130	15	145
Total	434	26	460

- a) Calcule los perfiles fila. ¿En qué turno es mayor la proporción de errores de medicación?
b) Calcule los perfiles columna. ¿Qué turno aporta más errores al total?
c) ¿Qué implicaciones tiene esto para la gestión de calidad en enfermería?

Solución:

```
# Tabla errores de medicación por turno
tabla_med <- matrix(c(156, 4, 148, 7, 130, 15),
                    nrow = 3, byrow = TRUE,
                    dimnames = list(
                      Turno = c("Mañana", "Tarde", "Noche"),
                      Medicacion = c("Correcta", "Error")
                    ))

cat("=== Perfiles fila (tasa de error por turno) ===\n")

## === Perfiles fila (tasa de error por turno) ===

pf_med <- round(prop.table(tabla_med, 1) * 100, 2)
print(pf_med)

##           Medicacion
## Turno   Correcta Error
## Mañana    97.50  2.50
## Tarde     95.48  4.52
## Noche     89.66 10.34

cat("\n=== Perfiles columna (distribución de errores) ===\n")

##
## === Perfiles columna (distribución de errores) ===

pc_med <- round(prop.table(tabla_med, 2) * 100, 1)
print(pc_med)

##           Medicacion
## Turno   Correcta Error
## Mañana    35.9 15.4
## Tarde     34.1 26.9
## Noche     30.0 57.7
```

a) **Perfiles fila - tasa de error por turno:**

- Mañana: $4/160 = 2.5\%$
- Tarde: $7/155 = 4.5\%$
- Noche: $15/145 = 10.3\%$ (mayor proporción de errores)

b) El turno de noche aporta el **57.7%** de todos los errores de medicación.

c) **Implicaciones para gestión de calidad:**

- Implementar verificación doble (double-check) en el turno de noche.
- Revisar la carga laboral nocturna (ratio enfermera/paciente).
- Implementar sistemas de dispensación automatizada.
- Programar capacitaciones específicas para personal nocturno.
- Analizar si la fatiga o la complejidad de los pacientes nocturnos contribuyen.

6.5 Ejercicio 35

Use R para construir y analizar una tabla de contingencia con los datos de un estudio sobre **adherencia al tratamiento** en pacientes con HTA según **nivel educativo**:

```
# Datos de adherencia y nivel educativo
set.seed(7)
nivel_edu <- c(rep("Primaria", 40), rep("Secundaria", 50), rep("Superior", 35))
adherencia <- c(
  sample(c("Adherente", "No adherente"), 40, replace=TRUE, prob=c(0.55, 0.45)),
  sample(c("Adherente", "No adherente"), 50, replace=TRUE, prob=c(0.68, 0.32)),
  sample(c("Adherente", "No adherente"), 35, replace=TRUE, prob=c(0.80, 0.20))
)

df_adher <- data.frame(Nivel = nivel_edu, Adherencia = adherencia)

# Tabla de contingencia
tabla_adher <- table(df_adher$Nivel, df_adher$Adherencia)
cat("=== Tabla de contingencia ===\n")

## === Tabla de contingencia ===
print(addmargins(tabla_adher))

##
##           Adherente No adherente Sum
##  Primaria           24           16  40
##  Secundaria          33           17  50
##  Superior            31            4  35
##  Sum                 88           37 125


cat("\n=== Perfiles fila (%) ===\n")

##
## === Perfiles fila (%) ===
print(round(prop.table(tabla_adher, 1) * 100, 1))

##
##           Adherente No adherente
##  Primaria          60.0          40.0
##  Secundaria          66.0          34.0
```

```
##      Superior      88.6      11.4
# Gráfico
df_plot_adher <- as.data.frame(prop.table(tabla_adher, 1) * 100)
colnames(df_plot_adher) <- c("Nivel", "Adherencia", "Proporcion")
df_plot_adher$Nivel <- factor(df_plot_adher$Nivel,
                             levels = c("Primaria", "Secundaria", "Superior"))

ggplot(df_plot_adher, aes(x = Nivel, y = Proporción, fill = Adherencia)) +
  geom_col(alpha = 0.85) +
  scale_fill_manual(values = c("#1565C0", "#EF5350")) +
  labs(x = "Nivel educativo", y = "Proporción (%)",
       title = "Adherencia al tratamiento de HTA según nivel educativo") +
  theme_minimal()
```



6.6 Ejercicio 36

Se realizó un estudio en 200 pacientes con diabetes tipo 2 para analizar la relación entre **actividad física** (sedentario, moderado, activo) y **control glucémico** ($HbA1c < 7\%$ vs 7%). Use R para construir y analizar la tabla:

```
# Datos: actividad física y control glucémico
tabla_dm <- matrix(c(25, 55, 40, 30, 35, 15),
                  nrow = 3, byrow = TRUE,
                  dimnames = list(
                    Actividad = c("Sedentario", "Moderado", "Activo"),
                    Control = c("HbA1c >= 7%", "HbA1c < 7%")
                  ))

cat("=== Tabla de contingencia ===\n")
```

```
## === Tabla de contingencia ===
print(addmargins(tabla_dm))

##          Control
## Actividad  HbA1c >= 7% HbA1c < 7% Sum
## Sedentario      25      55  80
## Moderado        40      30  70
## Activo          35      15  50
## Sum            100     100 200

cat("\n=== Perfiles fila (%) ===\n")

##
## === Perfiles fila (%) ===
pf_dm <- round(prop.table(tabla_dm, 1) * 100, 1)
print(pf_dm)

##          Control
## Actividad  HbA1c >= 7% HbA1c < 7%
## Sedentario      31.2      68.8
## Moderado        57.1      42.9
## Activo          70.0      30.0

cat("\nInterpretación:\n")


##
## Interpretación:
cat("Proporción con buen control (HbA1c < 7%):\n")

## Proporción con buen control (HbA1c < 7%):
for(i in 1:3) cat(" ", rownames(tabla_dm)[i], ":", pf_dm[i,2], "%\n")

## Sedentario : 68.8 %
## Moderado : 42.9 %
## Activo : 30 %

# Visualización
df_dm <- as.data.frame.table(pf_dm)
colnames(df_dm) <- c("Actividad", "Control", "Proporcion")
df_dm$Actividad <- factor(df_dm$Actividad,
                          levels = c("Sedentario", "Moderado", "Activo"))

ggplot(df_dm, aes(x = Actividad, y = Proporcion, fill = Control)) +
  geom_col(position = "dodge", alpha = 0.85) +
  scale_fill_manual(values = c("#EF5350", "#1565C0")) +
  geom_text(aes(label = paste0(Proporcion, "%")),
            position = position_dodge(width = 0.9),
            vjust = -0.3, size = 3.5) +
  labs(x = "Nivel de actividad física", y = "Proporción (%)",
       title = "Control glucémico según nivel de actividad física en DM tipo 2") +
  theme_minimal()
```



7 Visualización y Lectura Crítica de Tablas

7.1 Ejercicio 37

El siguiente extracto corresponde a la **Tabla 1** de un artículo clínico sobre rehabilitación cardíaca publicado en una revista indexada. Lea la tabla e interprete:

Variable	Media (DE) o n (%)	Rango
Edad (años)	62.4 (9.8)	40–78
Peso (kg)	78.3 (14.2)	52–115
FC reposo (lpm)	74.5 (11.3)	52–108
PAS (mmHg)	138.2 (18.6)	98–185
6MWT al ingreso (m)	285.3 (68.4)	120–450
Sexo masculino	68 (56.7%)	—
HTA	95 (79.2%)	—
Diabetes	42 (35.0%)	—
n total	120	

- ¿Cuál es la unidad estadística y cuántas hay?
- Para la variable 6MWT al ingreso: ¿qué representan 285.3 y 68.4?
- ¿Por qué la FC mínima de 52 lpm y máxima de 108 lpm son valores plausibles en esta población?
- Si la mediana de la 6MWT fuera 260 m (no reportada), ¿qué indicaría esto sobre la distribución?
- ¿Qué medida reportarías para la variable “HTA” y por qué?

Solución:

- La **unidad estadística** es cada paciente con cardiopatía inscrito en el programa de rehabilitación cardíaca. Hay **120 pacientes** en total.

- b) Para la 6MWT: **285.3 m** es la **media** (distancia promedio recorrida al ingreso al programa) y **68.4 m** es la **desviación estándar** (dispersión alrededor de la media). Se reporta en formato $\bar{x}$ (DE) como es convención en artículos biomédicos.
- c) Una FC de 52 lpm puede ser normal en pacientes con beta-bloqueadores o muy entrenados físicamente; 108 lpm puede verse en pacientes con insuficiencia cardíaca descompensada o sin medicación controlada. Ambos son valores plausibles para una población heterogénea con cardiopatía.
- d) Si la media (285.3 m) > mediana (260 m), la distribución estaría **sesgada a la derecha**: algunos pacientes con muy buena capacidad funcional elevan la media, pero la mayoría camina menos de 285 m. Para reportar el dato central en distribuciones asimétricas, sería más apropiado reportar la mediana.
- e) Para la variable **HTA** (dicotómica/nominal) se reporta la **frecuencia absoluta y relativa** (n y %) como aparece en la tabla: 95 (79.2%). No tiene sentido calcular media ni DE para variables nominales dicotómicas.

7.2 Ejercicio 38

Analice críticamente el siguiente párrafo de la sección de resultados de un artículo:

“Los 45 pacientes del grupo intervención presentaron una mejoría significativa en la escala EVA, con una reducción promedio de 2.8 ± 1.2 puntos (de 6.5 ± 1.8 a 3.7 ± 1.4 puntos, $p < 0.001$). La mediana de reducción fue de 2.5 puntos (RIC: 1.5–3.8). El 82.2% de los pacientes redujo su puntuación EVA en al menos 2 puntos (MCID: mínima diferencia clínicamente importante).”

- a) ¿Qué significa “ 6.5 ± 1.8 ”? ¿Qué tipo de variable es la EVA y qué implica para el análisis?
- b) ¿Por qué se reportan tanto la media $\pm$ DE como la mediana y RIC?
- c) ¿Qué indica el RIC de 1.5–3.8 sobre la distribución de la reducción?
- d) ¿Qué significado clínico tiene el 82.2% que supera el MCID?

Solución:

- a) “ **6.5 ± 1.8** ” significa que la puntuación EVA media basal fue 6.5 puntos con una desviación estándar de 1.8 puntos. La escala EVA es **ordinal** (valores discretos del 0 al 10). Si bien se reporta la media, esto es convencional en estudios clínicos; técnicamente, los métodos no paramétricos serían más apropiados para variables ordinales. En la práctica, la media de la EVA se acepta cuando el rango es suficientemente amplio (0–10).
- b) Se reportan ambas medidas porque la distribución de la reducción podría no ser perfectamente simétrica: la media $\pm$ DE asume aproximación normal (útil para comparaciones estadísticas), mientras que la mediana y RIC son medidas robustas que complementan la descripción sin supuestos distribucionales.
- c) Un RIC de 1.5–3.8 indica que el **50% central** de los pacientes redujo su EVA entre 1.5 y 3.8 puntos. El rango es relativamente amplio (2.3 puntos), sugiriendo **heterogeneidad en la respuesta**: algunos pacientes tuvieron reducciones mínimas y otros sustanciales.
- d) El 82.2% que supera el MCID (2 puntos de reducción) tiene un significado clínico crucial: no basta con que la reducción sea estadísticamente significativa ($p < 0.001$) —también debe ser **clínicamente relevante**. Un 82.2% indica que la intervención fue clínicamente importante para la gran mayoría de los pacientes, no solo estadísticamente significativa.

7.3 Ejercicio 39

El siguiente diagrama de cajas muestra la **frecuencia cardíaca máxima alcanzada en prueba de esfuerzo** en tres grupos de pacientes:

(Reconstruya el gráfico con R y responda las preguntas)


```

# FC máxima en prueba de esfuerzo por grupo
set.seed(2025)
controles    <- round(rnorm(30, mean = 165, sd = 12))
rehabilitados <- round(rnorm(30, mean = 148, sd = 15))
sedentarios  <- round(rnorm(30, mean = 132, sd = 18))

df_fcmax <- data.frame(
  FC = c(controles, rehabilitados, sedentarios),
  Grupo = factor(rep(c("Control sano", "Rehabilitación\ncardíaca", "Sedentario\ncon cardiopatía"),
    each = 30),
    levels = c("Sedentario\ncon cardiopatía", "Rehabilitación\ncardíaca", "Control sano"))
)

# Boxplot comparativo
ggplot(df_fcmax, aes(x = Grupo, y = FC, fill = Grupo)) +
  geom_boxplot(alpha = 0.75, outlier.color = "#C62828", outlier.size = 2.5) +
  geom_jitter(width = 0.15, alpha = 0.3, size = 1.5) +
  scale_fill_manual(values = c("#EF5350", "#FFA726", "#66BB6A"), guide = "none") +
  labs(x = "", y = "FC máxima (lpm)",
    title = "FC máxima en prueba de esfuerzo según grupo",
    caption = "Puntos: valores individuales | Caja: Q1-Q3 | Línea central: mediana") +
  theme_minimal(base_size = 12)

```



```

# Estadísticas descriptivas por grupo
df_fcmax %>%
  group_by(Grupo) %>%
  summarise(

```

```

Media   = round(mean(FC), 1),
Mediana = median(FC),
DE      = round(sd(FC), 1),
Q1      = quantile(FC, 0.25),
Q3      = quantile(FC, 0.75)
) %>%
knitr::kable(caption = "Estadísticas descriptivas de FC máxima por grupo")

```

Table 24: Estadísticas descriptivas de FC máxima por grupo

Grupo	Media	Mediana	DE	Q1	Q3
Sedentario con cardiopatía Rehabilitación cardíaca	129.2	125.0	19.6	116.25	143.75
Control sano	167.4	165.5	11.7	161.25	173.75

- ¿Qué grupo alcanza mayor FC máxima en promedio? ¿Cuál tiene mayor variabilidad?
- Interprete clínicamente las diferencias entre grupos.
- ¿Hay datos atípicos en algún grupo? ¿Cómo los identifica en el boxplot?

Solución:

- El grupo **Control sano** alcanza la mayor FC máxima (media 165 lpm). El grupo **Sedentario con cardiopatía** tiene la mayor variabilidad relativa (mayor amplitud de la caja y bigotes), evidenciando heterogeneidad en la capacidad funcional de los pacientes cardíacos no rehabilitados.
- Interpretación clínica:**
 - Los controles sanos alcanzan FC máximas más elevadas, coherente con su mayor reserva cardíaca.
 - Los pacientes en rehabilitación cardíaca mejoran su capacidad funcional respecto a los sedentarios con cardiopatía, pero no alcanzan los valores de controles sanos.
 - La mayor variabilidad en el grupo sedentario con cardiopatía refleja la heterogeneidad de las cardiopatías (leve vs severa) y el nivel de condición física basal.
- Los datos atípicos en el boxplot se identifican como **puntos individuales** que quedan fuera de los bigotes (más allá de las vallas de Tukey). Aparecerían marcados en rojo. Si hay puntos visibles fuera de las cajas, indican casos con FC máxima inusualmente alta o baja para su grupo, que merecen revisión clínica.

7.4 Ejercicio 40

Ejercicio Integrador: Un equipo de investigación de la Universidad Nacional de Colombia realizó un estudio descriptivo sobre el perfil de pacientes con EPOC en un programa de rehabilitación pulmonar. Se analizaron las siguientes variables en 50 pacientes.

Utilice R para realizar un **análisis descriptivo completo** con tablas e interpretaciones clínicas.

```

# Base de datos: pacientes con EPOC en rehabilitación pulmonar
set.seed(2024)
n_pac <- 50

epoc_df <- data.frame(
  # Variables continuas
  edad = round(rnorm(n_pac, mean = 67, sd = 8)),

```

```

imc      = round(rnorm(n_pac, mean = 26.5, sd = 4.2), 1),
spo2     = round(rnorm(n_pac, mean = 88, sd = 4)),
vef1_pct = round(rnorm(n_pac, mean = 48, sd = 12)),
seis_mwt = round(rnorm(n_pac, mean = 290, sd = 65)),
eva_disnea = round(runif(n_pac, 3, 8)),

# Variables categóricas
sexo      = sample(c("Masculino", "Femenino"), n_pac, replace=TRUE, prob=c(0.60, 0.40)),
estadio   = sample(c("GOLD II", "GOLD III", "GOLD IV"), n_pac,
                    replace=TRUE, prob=c(0.35, 0.45, 0.20)),
tabaquismo = sample(c("Activo", "Ex-fumador", "Nunca"), n_pac,
                    replace=TRUE, prob=c(0.20, 0.65, 0.15))
)

# Ajustar SpO2 a rango plausible
epoc_df$spo2 <- pmin(pmax(epoc_df$spo2, 75), 97)
epoc_df$vef1_pct <- pmin(pmax(epoc_df$vef1_pct, 20), 79)

# === Estadísticas descriptivas: variables continuas ===
cat("==== ESTADÍSTICAS DESCRIPTIVAS - EPOC REHABILITACIÓN =====\n\n")

## ===== ESTADÍSTICAS DESCRIPTIVAS - EPOC REHABILITACIÓN =====

vars_continuas <- c("edad", "imc", "spo2", "vef1_pct", "seis_mwt", "eva_disnea")
labels_vars    <- c("Edad (años)", "IMC (kg/m²)", "SpO (%)", "VEF (% predicho)", "6MWT (m)", "EVA disnea")

resumen_tabla <- sapply(vars_continuas, function(v) {
  x <- epoc_df[[v]]
  c(n      = length(x),
    Media  = round(mean(x), 1),
    DE     = round(sd(x), 1),
    Mediana = round(median(x), 1),
    Q1     = round(quantile(x, 0.25), 1),
    Q3     = round(quantile(x, 0.75), 1),
    Min    = min(x),
    Max    = max(x))
})
colnames(resumen_tabla) <- labels_vars

knitr::kable(t(resumen_tabla), caption = "Estadísticas descriptivas: variables continuas")

```

Table 25: Estadísticas descriptivas: variables continuas

	n	Media	DE	Mediana	Q1.25%	Q3.75%	Min	Max
Edad (años)	50	66.4	8.5	67.5	62.2	71.0	41.0	83.0
IMC (kg/m²)	50	26.1	4.2	26.4	23.4	29.5	17.6	33.4
SpO (%)	50	88.1	3.9	88.0	85.0	90.8	81.0	97.0
VEF (% predicho)	50	51.0	12.4	51.5	43.0	59.8	20.0	77.0
6MWT (m)	50	297.0	53.2	299.0	258.5	329.0	112.0	413.0
EVA disnea	50	5.6	1.5	6.0	5.0	7.0	3.0	8.0

```

# === Tablas de frecuencia: variables categóricas ===
cat("\n=== Variable: Sexo ===\n")

```

```
##
## === Variable: Sexo ===
tab_sexo <- table(epoc_df$sexo)
print(cbind(n = tab_sexo, "%" = round(prop.table(tab_sexo)*100, 1)))

##          n  %
## Femenino 22 44
## Masculino 28 56
cat("\n=== Variable: Estadio GOLD ===\n")

##
## === Variable: Estadio GOLD ===
tab_gold <- table(epoc_df$estadio)
print(cbind(n = tab_gold, "%" = round(prop.table(tab_gold)*100, 1)))

##          n  %
## GOLD II  21 42
## GOLD III 18 36
## GOLD IV  11 22
cat("\n=== Variable: Tabaquismo ===\n")

##
## === Variable: Tabaquismo ===
tab_tab <- table(epoc_df$tabaquismo)
print(cbind(n = tab_tab, "%" = round(prop.table(tab_tab)*100, 1)))

##          n  %
## Activo    9 18
## Ex-fumador 35 70
## Nunca     6 12
# === Tabla de contingencia: Sexo x Estadio GOLD ===
cat("\n=== Tabla de contingencia: Sexo x Estadio GOLD ===\n")

##
## === Tabla de contingencia: Sexo x Estadio GOLD ===
tabla_cruzada <- table(epoc_df$sexo, epoc_df$estadio)
print(addmargins(tabla_cruzada))

##
##          GOLD II GOLD III GOLD IV Sum
## Femenino      10      8      4  22
## Masculino      11     10      7  28
## Sum           21     18     11  50
cat("\n=== Perfiles fila (% por sexo) ===\n")

##
## === Perfiles fila (% por sexo) ===
print(round(prop.table(tabla_cruzada, 1) * 100, 1))

##
##          GOLD II GOLD III GOLD IV
## Femenino      45.5     36.4    18.2
```

```
## Masculino 39.3 35.7 25.0


# === Panel de gráficos ===
p_spo2 <- ggplot(epoc_df, aes(x = estadio, y = spo2, fill = estadio)) +
  geom_boxplot(alpha = 0.75, outlier.color = "#C62828") +
  scale_fill_manual(values = c("#FFA726", "#EF5350", "#B71C1C"), guide = "none") +
  labs(x = "Estadio GOLD", y = "SpO2 (%)",
       title = "SpO2 según severidad EPOC") +
  theme_minimal()

p_mwt <- ggplot(epoc_df, aes(x = seis_mwt, fill = estadio)) +
  geom_histogram(bins = 10, alpha = 0.75, position = "identity", color = "white") +
  scale_fill_manual(values = c("#FFA726", "#EF5350", "#B71C1C")) +
  labs(x = "6MWT (m)", y = "Frecuencia",
       title = "Distribución 6MWT por estadio", fill = "Estadio") +
  theme_minimal()

p_scatter <- ggplot(epoc_df, aes(x = vef1_pct, y = seis_mwt, color = estadio)) +
  geom_point(alpha = 0.7, size = 2.5) +
  scale_color_manual(values = c("#FFA726", "#EF5350", "#B71C1C")) +
  labs(x = "VEF1 (% predicho)", y = "6MWT (m)",
       title = "VEF1 vs capacidad funcional (6MWT)", color = "Estadio") +
  theme_minimal()

p_bar <- ggplot(epoc_df, aes(x = tabaquismo, fill = estadio)) +
  geom_bar(position = "fill", alpha = 0.85) +
  scale_fill_manual(values = c("#FFA726", "#EF5350", "#B71C1C")) +
  scale_y_continuous(labels = scales::percent) +
  labs(x = "Tabaquismo", y = "Proporción", fill = "Estadio",
       title = "Estadio GOLD según tabaquismo") +
  theme_minimal()

gridExtra::grid.arrange(p_spo2, p_mwt, p_scatter, p_bar, ncol = 2)
```



```

# === Detección de datos atípicos ===
cat("\n=== Datos atípicos por variable (criterio de Tukey) ===\n")

##
## === Datos atípicos por variable (criterio de Tukey) ===
for(v in vars_continuas[1:5]) {
  x <- epoc_df[[v]]
  Q1 <- quantile(x, 0.25); Q3 <- quantile(x, 0.75); RIC <- IQR(x)
  vi <- Q1 - 1.5*RIC; vs <- Q3 + 1.5*RIC
  atip <- x[x < vi | x > vs]
  cat(v, ":", if(length(atip)==0) "sin atípicos" else paste(length(atip), "atípico(s):", paste(atip, col
})

## edad : 1 atípico(s): 41
## imc : sin atípicos
## spo2 : sin atípicos
## vef1_pct : sin atípicos
## seis_mwt : 1 atípico(s): 112

# === Resumen clínico ===
cat("\n===== RESUMEN CLÍNICO =====\n")

##
## ===== RESUMEN CLÍNICO =====
cat("Perfil de los", n_pac, "pacientes en programa de rehabilitación pulmonar:\n")

## Perfil de los 50 pacientes en programa de rehabilitación pulmonar:
cat("- Edad media:", round(mean(epoc_df$edad), 1), "años (mayoría adultos mayores)\n")

## - Edad media: 66.4 años (mayoría adultos mayores)
cat("- SpO2 media:", round(mean(epoc_df$spo2), 1), "% (hipoxemia leve-moderada)\n")

## - SpO2 media: 88.1 % (hipoxemia leve-moderada)
cat("- VEF medio:", round(mean(epoc_df$vef1_pct), 1), "% predicho (obstrucción moderada-severa)\n")

## - VEF medio: 51 % predicho (obstrucción moderada-severa)
cat("- 6MWT medio:", round(mean(epoc_df$seis_mwt), 1), "m (capacidad funcional reducida)\n")

## - 6MWT medio: 297 m (capacidad funcional reducida)
cat("- Estadio predominante:",
  names(sort(tab_gold, decreasing=TRUE)[1]),
  "(", max(prop.table(tab_gold))*100, "% )\n")

## - Estadio predominante: GOLD II ( 42 % )
cat("- Ex-fumadores:", round(prop.table(tab_tab)["Ex-fumador"]*100, 1), "%\n")

## - Ex-fumadores: 70 %

```

Interpretación clínica integradora:

El análisis descriptivo revela que los pacientes con EPOC en rehabilitación pulmonar son predominantemente adultos mayores (media ~67 años) con obstrucción moderada-severa (VEF ~48%), hipoxemia leve-moderada (SpO₂ ~88%) y capacidad funcional reducida (6MWT ~290 m, por debajo del umbral de riesgo de 350 m). La mayoría son ex-fumadores, coherente con la etiología de la enfermedad. Las diferencias por estadio

GOLD en SpO₂ y 6MWT confirman el gradiente de severidad: a mayor estadio GOLD, menor SpO₂ y menor distancia en la prueba de marcha. Este análisis descriptivo inicial es fundamental antes de cualquier análisis inferencial para detectar errores, entender la distribución de las variables y seleccionar las pruebas estadísticas apropiadas.